



SVEUČILIŠTE U ZAGREBU  
FAKULTET ORGANIZACIJE I INFORMATIKE  
VARAŽDIN

Aplikacija za analizu velikih količina  
podataka (NoSQL, map/reduce) -  
polustrukturirane baze podataka -  
MongoDB - sa sučeljem na LibreOffice Calc  
Projektni rad

**Tomislav Pertinač**  
br. indeksa: 45274/16-R

Mentor:  
**Doc. dr. sc. Markus Schatten**

Varaždin, 29. kolovoza 2017.

# Sadržaj

1	Uvod	1
2	Big Data	2
3	Polustrukturirane baze podataka	3
4	NoSQL	4
5	MongoDB	6
6	Izrada baze podataka u MongoDB	7
7	Aplikacija	10
8	Zaključak	22
	Bibliografija	22

# Poglavlje 1

## Uvod

U ovome projektu je opisan i prikazan princip rada polustrukturiranih baza podataka, te je prikazano na koji način možemo napraviti i prikazati analizu velikih količina podataka. Aplikacija za analizu velikih količina podataka je napravljena pomoću NoSQL baze, odnosno korištena je MongoDB baza podataka. Za programski logiku je korišten programski jezik python, a samo sučelje, odnosno prikaz podataka i analiza je prikazana na LibreOffice tablični kalkulator.

Aplikacija je funkcionalna na Linux platformi, makar uz malu nadogradnju bi lako bila i funkcionalna na Windows platformi. Konkretna operacijski sustav koji se koristio za razvijanje aplikacije i na kojem aplikacija radi je Ubuntu 16.04 lts. U ovom projektnom radu upoznat ćemo se što je to big data i što su polustrukturirane baze podataka. Vidjet ćemo što je to NoSQL po čemu je on različit ili sličan sa SQL-om, bit će opisan MongoDB te će bit prikazana arhitektura, implementacija te primjer korištenja same aplikacije.

## Poglavlje 2

# Big Data

Big Data opisuje ogromne količine strukturiranih ili nestrukturiranih podataka s kojima je vrlo teško raditi na klasičan način i korištenjem standardnih alata ili relacijskih baza podataka. Kod big data se često susrećemo sa nazivom V3 odnosno to označava *volume, velocity i variety*. Ponegdje se može još i susreti sa još dvije karakteristike a to su *varijabilnost i vjerodostojnost*.

Što se tiče volumena sam naziv big data sve objašnjava. On opisuje ogromnu količinu odnosno volumen podataka koji se tu javljaju.

Raznolikost govori o tome da podaci nisu dovoljno strukturirani, da su često neuredni i nabacani iz raznih izvora i na razne načine.

Iako se ovdje govori o velikoj količini podataka svejedno nam je važna brzina da dovoljno brzo i u nekom konačnom, realnom i prihvatljivom vremenu izvučemo za korisnika važne mu podatke koje se kasnije i koriste pri kreiranju izvještaja i za analizu podataka.

Pošto se u big data prikupljaju mnogi podaci te se u toj gomili podataka mogu vidjeti realna stanja stvari a to znači i kvalitetu podataka pa zbog toga se negdje i spominje termin vjerodostojnosti u big data.

Osim tog termina spominje se još i termin varijabilnosti koji označava da se značenje podataka stalno mijenja. U nekim slučajevima čak se zna i naći na još dvije karakteristike. Jedna od njih je vizualizacija gdje je jasno da iz te velike količine podataka se mogu izvući oni bitni i ključni za nekog korisnika, i na temelju njih se mogu raditi analiz i grafovi iz kojih možemo iščitati neke važne informacije. Te drugi termin je vrijednost, a tu se smatra upravo poslovna vrijednost ili trošak pri korištenju big data tehnologija gdje se važe koliko zapravo korištenje big data tehnologija ima benefita za samo poslovanje.(Wik, 2017)

## Poglavlje 3

# Polustrukturirane baze podataka

U današnje vrijeme gdje većina svijeta ima pristup internetu, ne čudi da se javila potreba za nekom drugim načinom implementacije baza podataka osim za relacijskim modelom. Tako se zbog sve više korisnika povećava i konstatno obujam podataka koji kruži preko mreže. Tu u igru dolaze polustrukturirani podaci u kojima su informacije sadržane unutar podataka pa se i još znaju zvati "self-describing" ili samo opisne. Polustrukturirani modeli podataka se najčešće prikazuju preko stabla. Kod stabla postoji korijen koji predstavlja neki objekt, a vrijednosti se nalaze u svim ostalim čvorovima tog stabla.

Polustrukturirani podaci su najčešće prikazani pomoću OEM-a odnosno Object exchange modela. Isto tako polustrukturirani podaci su često oblikovani pomoću JSON-a ili XML-a. Dok je XML vrlo fleksibilan te ima veliku ulogu u razmjeni raznih podataka na webu, JSON ima prednost što je lakše čitljiv ljudima i jednostavniji računalima za rad sa njim.

Kod polustrukturiranih tipova podataka je prednost što objekti ne moraju imati iste atribute, te atributi ne moraju biti isti tip podataka, a samim polustrukturiranim modelom bez problema se mogu prikazati i strukturirani podaci.

Neki prednosti i nedostaci su dolje navedeni

Prednosti:

- Programeri koji rade s objektima ne moraju brinuti o neslaganjima koje prouzročuju objekti već se s objektima lako manipulira sa light-weight libraryjem.
- Podrška za ugniježđenim ili hijerarhijskim podacima pojednostavljuje model podataka koji inače predstavlja složene odnose između entiteta.
- Podrška za listama objekata pojednostavljuje model podataka pri čemu se izbjegava nered konverzije lista u relacijski model podataka.

Nedostaci:

- Tradicionalni model relacijskih podataka ima popularan i gotov Query Language - SQL.
- Uklanjanjem ograničenja iz modela podataka sve se manje promišlja da je potrebno razraditi unos podataka.

(SSD, 2016)

## Poglavlje 4

# NoSQL

NoSQL baze podataka su baze za pohranu i dohvaćanje podataka koje koriste potpuno drugačije principe spram klasičnih relacijskih baza podataka koji koriste tablasti model. NoSQL se još i nazivaju Not Only SQL a se da zaključiti da zapravo podržavaju standardne SQL upite ali i više od toga. Najbitnija razlika je ta da ne koriste Join upite koji su veoma specifični za klasični SQL. Dok spomenemo NoSQL baze podataka tada to povezujemo i sa pojmovima da nisu relacijske, da su distribuirane, otvorenog koda i horizontalno skalabilne. Što se tiče tipova NoSQL baza podataka, postoji ih nekoliko a to su:

- Dokumentne baze u kojima se uparuje svaki ključ s kompleksnom podatkovnom strukturom poznatom kao dokument. Dokumenti mogu sadržavati razne parove ključ-vrijednost, parove ključ-polje ili čak i ugniježene dokumente.
- Grafičke baze se koriste da sačuvaju informacije o nekoj mreži podataka, kao što su na primjer socijalne mreže.
- Ključ-vrijednost je najjednostavnija NoSQL baza podataka. Svaka pojedina stavka ima ime atributa ili ključ povezanu sa vrijednost.
- Široko-stupaste baze kao što je npr. Cassandra i HBase su optimizirane za upite nad velikim skupovima podataka. te spremaju stupce podataka zajedno umjesto u redove.

NoSQL je odgovor na relacijske baze podataka koje imaju čvrstu strukturu. U današnje vrijeme se sve više koriste agilne metodologije razvoja programskog proizvoda te zbog toga se i često mijenja struktura podataka te tu NoSQL ima prednost jer jednostavnije se nosi sa tim izazovima i zahtjevima. Na slici(4.1). možemo vidjeti ukratko koje su razlike između SQL baza podataka i NoSQL baza podataka. (NoS, 2017)

## NoSQL vs. SQL Summary

	SQL Databases	NOSQL Databases
<b>Types</b>	One type (SQL database) with minor variations	Many different types including key-value stores, document databases, wide-column stores, and graph databases
<b>Development History</b>	Developed in 1970s to deal with first wave of data storage applications	Developed in late 2000s to deal with limitations of SQL databases, especially scalability, multi-structured data, geo-distribution and agile development sprints
<b>Examples</b>	MySQL, Postgres, Microsoft SQL Server, Oracle Database	MongoDB, Cassandra, HBase, Neo4j
<b>Data Storage Model</b>	Individual records (e.g., 'employees') are stored as rows in tables, with each column storing a specific piece of data about that record (e.g., 'manager,' 'date hired,' etc.), much like a spreadsheet. Related data is stored in separate tables, and then joined together when more complex queries are executed. For example, 'offices' might be stored in one table, and 'employees' in another. When a user wants to find the work address of an employee, the database engine joins the 'employee' and 'office' tables together to get all the information necessary.	Varies based on database type. For example, key-value stores function similarly to SQL databases, but have only two columns ('key' and 'value'), with more complex information sometimes stored as BLOBs within the 'value' columns. Document databases do away with the table-and-row model altogether, storing all relevant data together in single 'document' in JSON, XML, or another format, which can nest values hierarchically.
<b>Schemas</b>	Structure and data types are fixed in advance. To store information about a new data item, the entire database must be altered, during which time the database must be taken offline.	Typically dynamic, with some enforcing data validation rules. Applications can add new fields on the fly, and unlike SQL table rows, dissimilar data can be stored together as necessary. For some databases (e.g., wide-column stores), it is somewhat more challenging to add new fields dynamically.
<b>Scaling</b>	Vertically, meaning a single server must be made increasingly powerful in order to deal with increased demand. It is possible to spread SQL databases over many servers, but significant additional engineering is generally required, and core relational features such as JOINS, referential integrity and transactions are typically lost.	Horizontally, meaning that to add capacity, a database administrator can simply add more commodity servers or cloud instances. The database automatically spreads data across servers as necessary.
<b>Development Model</b>	Mix of open-source (e.g., Postgres, MySQL) and closed source (e.g., Oracle Database)	Open-source
<b>Supports Transactions</b>	Yes, updates can be configured to complete entirely or not at all	In certain circumstances and at certain levels (e.g., document level vs. database level)
<b>Data Manipulation</b>	Specific language using Select, Insert, and Update statements, e.g. SELECT fields FROM table WHERE...	Through object-oriented APIs
<b>Consistency</b>	Can be configured for strong consistency	Depends on product. Some provide strong consistency (e.g., MongoDB, with tunable consistency for reads) whereas others offer eventual consistency (e.g., Cassandra).

Slika 4.1: SQL vs NoSQL ()

## Poglavlje 5

# MongoDB

MongoDB je open-source dokument baza podataka a zapis u MongoDB bazi zove se dokument, koji je podatkovna struktura sastavljena od parova ključeva i njihovih vrijednosti. MongoDB dokumenti su strukturom slični JSON objektima. Vrijednosti polja mogu uključivati i druge dokumente, polja te listu polja.

MongoDB sprema BSON dokumente u kolekcije. Što se tiče same razlike u terminologiji kod klasičnih relacijskih baza imamo tablice a to se kod MongoDB-a zovu kolekcije, isto tako redak se zove dokument a stupa je polje. Rad sa MongoDB-om može ići preko terminala odnosno komadnom linijom ili preko nekih programa za vizualizaciju i olakšano korištenje MongoDB-a kao što je Robomongo. MongoDB ne koristi baš klasične sql upite već pruža neke metode. Tako npr. imamo metode za unos dokumenata u kolekciju(`db.collection.insert()`), pa za klasičan selekt upit postoji metoda `find()` nad kojom možemo još i definirat neke dodatne uvjete. Isto tako imamo i metodu `update()`, `delete()` te `remove()`. Postoje i malo specifičnije nabrojene CRUD metode koje se mogu odnositi na samo jedan zapis u kolekciji ili više njih itd.

Operacije agregiranja procesiraju zapise podataka i vraćaju izračunate rezultate. Takve funkcije obrađuju podatke i prikazuju rezultat u potrebnom obliku. Agregirajuće operacije koriste kolekcije i dokumente kao ulaz i izlaz, poput upita. MongoDB pruža tri načina za izvršavanje agregacije podataka a to su agregacijski cjevovod, map-reduce te agregirajuće funkcije jednostavne svrhe. (Mon, 2016)



## Poglavlje 6

# Izrada baze podataka u MongoDB

Za početak trebamo skinuti i instalirati MongoDB bazu podataka. Pošto se za operacijski sustav koristi Ubuntu, to ćemo obaviti preko naredba u terminalu i apt sustava za upravljanje paketima.

Prvo utipkamo naredbu za uvođenje javnog ključa

```
sudo apt-key adv --keyserver hkp://keyserver.ubuntu.com:80
--recv 0C49F3730359A14518585931BC711F9BA15703C6
```

Zatim kreiramo listu datoteka za Ubuntu verziju koju koristimo, u ovom slučaju je to 16.04

```
echo "deb [arch=amd64,arm64]
http://repo.mongodb.org/apt/ubuntu/xenial/mongodb-org/3.4 multiverse"
| sudo tee /etc/apt/sources.list.d/mongodb-org-3.4.list
```

Nakon toga učitamo lokalnu bazu podataka paketa

```
sudo apt-get update
```

Sada konačno možemo skinuti i instalirati MongoDB

```
sudo apt-get install -y mongodb-org
```

Nakon što smo to odradili možemo pokrenuti lokalni server sa naredbom

```
sudo service mongod start
```

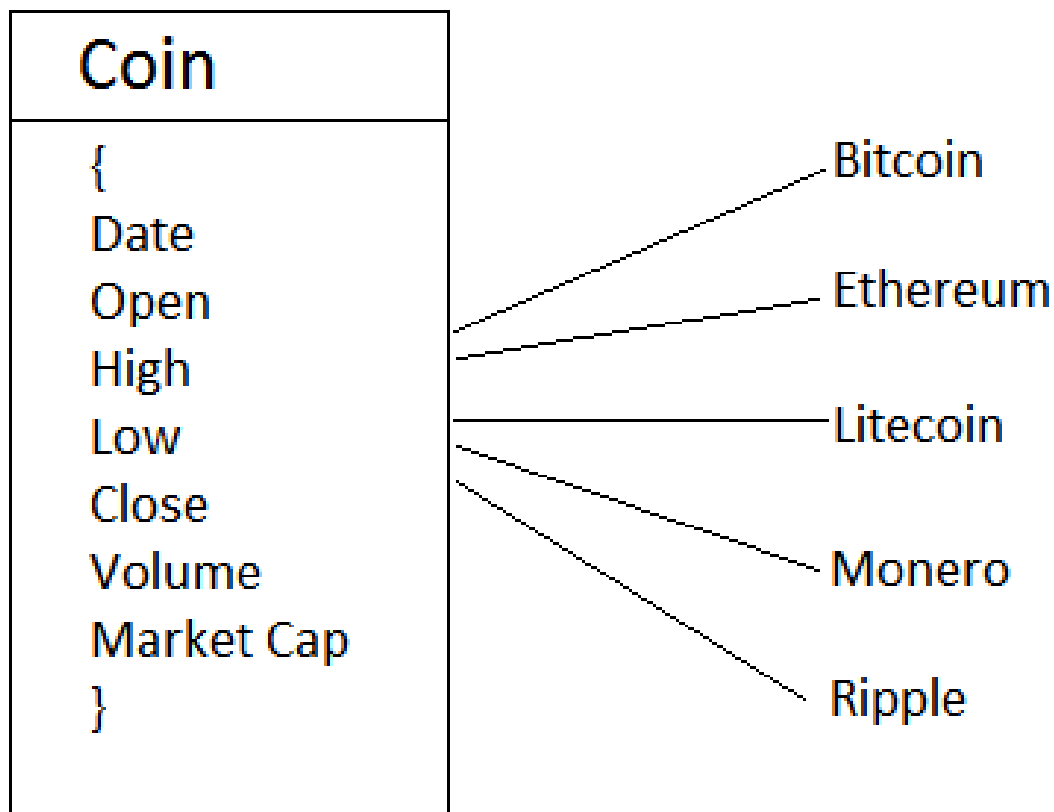
Naredbe za provjeru statusa servera, resetiranje i zaustavljanje su sljedeće:

```
sudo service mongod {status|restart|stop}
```

Kada bi htjeli nešto testirati i odraditi neke administratorske stvari onda bi utipkali naredbu *mongo* bi nam se tada otvorilo JavaScript shell sučelje za MongoDB. Za ovu aplikaciju koristimo gotove skupove podataka koji su vezani za rudarenja virtualnih valuta. Tako na slici(6.1) vidimo otprilike kako izgleda model baze u ovoj aplikaciji.

Dolje možemo vidjeti dio koda, odnosno JSON-a jednog od kriptovaluta:

```
{
  "Date": "Aug_15,_2017",
  "Open": 299.95,
```



Slika 6.1: Model baze

```
{  
  "High": 300.41,  
  "Low": 279.33,  
  "Close": 289.82,  
  "Volume": "1,051,800,000",  
  "Market_Cap": "28,195,800,000"  
}
```

Da konkretnije pojasnimo:

- Date : datu promatranja
- Open : Cijena na početku dana
- High : Najviša cijena u danu
- Low : Najniža cijena u danu
- Close : Cijena na kraju danu
- Volume : Volumen transakcija tog dana
- Market Cap : Tržišna kapitalizacija u USD

Za ovaj projekt smo kreirali novu bazu pod nazivom tbp:

```
# mongo  
> use tbp
```

Zatim smo svaki od skupa podataka dodali u bazu:


```
mongoimport --db tbp --collection bitcoin --file bitcoin.json  
--jsonArray  
mongoimport --db tbp --collection ethereum --file ethereum.json  
--jsonArray  
mongoimport --db tbp --collection litecoin --file litecoin.json  
--jsonArray  
mongoimport --db tbp --collection monero --file monero.json  
--jsonArray  
mongoimport --db tbp --collection ripple --file ripple.json  
--jsonArray
```

Nakon svih ovih radnji, naša baza je spremna za rad s aplikacijom.

## Poglavlje 7

# Aplikacija

Aplikacija u ovom projektu za logiku koristi python programski jezik. Konkretno koristio se PyCharm community ide za lakši razvoj aplikacije. Tako se u pythonu nalazi isprogramirana logika koja se povezuje na MongoDB bazu, radi određene radnji tako da dohvaća određene podake ovisno o upitu te ih zapisuje u LibreOffice Calc te ukoliko odaberemo određene radnje stvara i gafove kroz koje možemo vidjeti neku analizu stanja kriptovaluta(7.1).



Slika 7.1: Model aplikacije

Što se tiče same logike i koda, za početak imamo biblioteke koje koristimo. Tako nam subprocess služi da možemo pozivati programe van pythona kao npr terminal ili libreoffice calc. Nakon toga imamo biblioteku time koja nam koristi za pozivanje sleep metode. Biblioteke xlwt i pyoo nam služe za rad sa LibreOffice calcom, odnosno jedna je korištena za samo upisivanje a druga za izradu grafova. Biblioteka os nam služi za dohvaćanje putanje projekta. Biblioteka tkinter nam je osnovna biblioteka za prikaz objekata na ekran(prozor, gumbi, popisi). Te za kraj imamo pymongo biblioteku koja nam služi za spajanje na MongoDB bazu. (Pojman, 2017), (Machin, 2017)

```
import subprocess
import time
import xlwt
import pyoo
import os
import tkinter.messagebox
from tkinter import *
from pymongo import MongoClient
```

Zatim na početku prvo pozivamo konstruktor klase te se spajamo na bazu i spremamo našu tbp bazu u db varijablu koju dalje prosljeđujemo metodama koje će je koristiti kako se nebi trebali svaki puta ponovno spajati na bazu. Osim toga stvaramo početni prozor, gubove, listu, njihove funkcionalnosti i

položaj u prozoru.

```
class MiningCoins(Frame):

    def __init__(self, master):
        try:
            #subprocess.Popen(['service mongod start'], shell=True)
            #time.sleep(5)
            client = MongoClient('mongodb://localhost:27017/')
            db = client['tbp']
        except ConnectionRefusedError:
            tkinter.messageBox.showinfo('MongoDB_connection_error',
            'Nije moguće se spojiti na MongoDB!')
        frame = Frame(master)
        frame.grid()
        label = Label(frame, text = "Dobrodošli!")
        label.grid(row=0, column=1)
        btnCoin = Button(frame, text = "Prikaz po coinovima",
        command=lambda: self.coin(db))
        btnCoin.grid(row=1)
        btnKat = Button(frame, text = "Prikaz po kategorijama",
        command=lambda: self.category(db))
        btnKat.grid(row=2)
        btnGKat = Button(frame, text="Graficki prikaz za kategorije",
        command=self.grafKat)
        btnGKat.grid(row=2, column=1)
        lbGod = Listbox(frame, height=3, exportselection=0)
        lbGod.insert(0, "2017")
        lbGod.insert(1, "2016")
        lbGod.insert(2, "2015")
        lbGod.grid(row = 3)
        lbKat = Listbox(frame, height=6, exportselection=0)
        lbKat.insert(0, "Open")
        lbKat.insert(1, "High")
        lbKat.insert(2, "Low")
        lbKat.insert(3, "Close")
        lbKat.insert(4, "Volume")
        lbKat.insert(5, "Market_Cap")
        lbKat.grid(row=3, column=1)
        lbCoi = Listbox(frame, height=5, exportselection=0)
        lbCoi.insert(0, "Bitcoin")
        lbCoi.insert(1, "Ethereum")
        lbCoi.insert(2, "Litecoin")
        lbCoi.insert(3, "Monero")
        lbCoi.insert(4, "Ripple")
        lbCoi.grid(row=3, column=2)
```

```
btnP = Button(frame, text="Napravi pojedinačnu analizu",
command=lambda: self.analiza(db, lbGod.get(ACTIVE),
lbKat.get(ACTIVE), lbCoi.get(ACTIVE)))
btnP.grid(row=4, column=1)
btnQuit = Button(frame, text="Izadi", command=frame.quit)
btnQuit.grid(row=5, column=4)
```



Slika 7.2: Aplikacija

Prva metoda koju koristimo je `coin(db)` koja jednostavno dohvaća sve kolekcije iz baze i sve dokumente iz svake kolekcije i upisuje u LibreOffice Calc dokument na način da svaka kolekcija se nalazi u vlastitom sheetu.

```
def coin(self, db):
    bit = db.bitcoin.find()
    eth = db.ethereum.find()
    lit = db.litecoin.find()
    mon = db.monero.find()
    rip = db.ripple.find()

    cursors = list([bit, eth, lit, mon, rip])

    wb = xlwt.Workbook()

    sheetB = wb.add_sheet("Bitcoin")
    sheetE = wb.add_sheet("Ethereum")
    sheetL = wb.add_sheet("Litecoin")
    sheetM = wb.add_sheet("Monero")
    sheetR = wb.add_sheet("Ripple")

    sheet = list([sheetB, sheetE, sheetL, sheetM, sheetR])

    for s in sheet:
```

```
s.write(0, 0, 'Datum')
s.write(0, 1, 'Open')
s.write(0, 2, 'High')
s.write(0, 3, 'Low')
s.write(0, 4, 'Close')
s.write(0, 5, 'Volume')
s.write(0, 6, 'Market_Cap')

i = 0
for c in cursors:
    j = 1
    for row in c:
        sheet[i].write(j, 0, str(row['Date']))
        sheet[i].write(j, 1, float(row['Open']))
        sheet[i].write(j, 2, float(row['High']))
        sheet[i].write(j, 3, float(row['Low']))
        sheet[i].write(j, 4, float(row['Close']))
        sheet[i].write(j, 5, str(row['Volume']))
        sheet[i].write(j, 6, str(row['Market_Cap']))
        j = j + 1
    i = i + 1

reportDir = os.path.dirname(os.path.abspath('reports'))
            + "/reports/"
wb.save(reportDir + "coinovi.ods")
subprocess.call(['/usr/bin/localc', reportDir
                + 'coinovi.ods'])
```

Druga metoda `category(db)` također radi istu stvar da povlači sve kolekcije i sve dokumente svake od kolekcije ali ovoga puta spremamo te zapise na način da svaki sheet označava jednu kategoriju odnosno atribut koji je zajednički svim tim kolekcijama.

```
def category(self, db):
    lim = db.ethereum.count()

    eth = db.ethereum.find()
    bit = db.bitcoin.find().limit(lim)
    lit = db.litecoin.find().limit(lim)
    mon = db.monero.find().limit(lim)
    rip = db.ripple.find().limit(lim)

    cursors = list([bit, eth, lit, mon, rip])

    wb = xlwt.Workbook()
```

```
sheetO = wb.add_sheet("Open")
sheetH = wb.add_sheet("High")
sheetL = wb.add_sheet("Low")
sheetC = wb.add_sheet("Close")
sheetV = wb.add_sheet("Volume")
sheetMC = wb.add_sheet("Market_Cap")

sheet = list([sheetO, sheetH, sheetL,
              sheetC, sheetV, sheetMC])

for s in sheet:
    s.write(0, 0, 'Datum')
    s.write(0, 1, 'Bitcoin')
    s.write(0, 2, 'Ethereum')
    s.write(0, 3, 'Litecoin')
    s.write(0, 4, 'Monero')
    s.write(0, 5, 'Ripple')

i = 1
for row in bit:
    for s in sheet:
        s.write(i, 0, str(row['Date']))
    sheet[0].write(i, 1, float(row['Open']))
    sheet[1].write(i, 1, float(row['High']))
    sheet[2].write(i, 1, float(row['Low']))
    sheet[3].write(i, 1, float(row['Close']))
    sheet[4].write(i, 1, int(str(row['Volume']).replace(',', '')))
    sheet[5].write(i, 1, int(str(row['Market_Cap']).replace(',', '')))

    i = i + 1

j = 1
for c in cursors:
    i = 1
    for row in c:
        sheet[0].write(i, j, float(row['Open']))
        sheet[1].write(i, j, float(row['High']))
        sheet[2].write(i, j, float(row['Low']))
        sheet[3].write(i, j, float(row['Close']))
        sheet[4].write(i, j, int(str(row['Volume']).replace(',', '')))
        sheet[5].write(i, j, int(str(row['Market_Cap']).replace(',', '')))

        i = i + 1
```



```
j = j + 1

reportDir = os.path.dirname(os.path.abspath('reports'))
            + "/reports/"
wb.save(reportDir + "kategorije.ods")
subprocess.call(['/usr/bin/localc', reportDir
                + 'kategorije.ods'])
```

Treća metoda grafKat() prvo poziva terminal kako bi pokrenula dana naredba i kako bi se time napravio soffice socket kako bi uopće mogli koristiti funkcije pyoo biblioteke. Tako otvaramo dokument kategorije kojeg smo gore kreirali, ili vraćamo grešku ukoliko još nije kreiran. Zatim na temelju zapisa u Calc datoteci za svaki sheet radimo graf koji prikazuje usporedbu fluktuacija za određenu kategoriju po svakoj od kriptovaluta.

```
def grafKat(self):
    try:
        subprocess.Popen(['soffice
#####accept="socket,host=localhost,port=2002;urp;"
#####--norestore--nologo--nodefault#--headless'],
            shell=True)
        time.sleep(2)
        desktop = pyoo.Desktop('localhost', 2002)
        reportKat = os.path.dirname(os.path.abspath('reports'))
        + "/reports/kategorije.ods"
        doc = desktop.open_spreadsheet(reportKat)

        sheet1 = doc.sheets[0]
        sheet2 = doc.sheets[1]
        sheet3 = doc.sheets[2]
        sheet4 = doc.sheets[3]
        sheet5 = doc.sheets[4]
        sheet6 = doc.sheets[5]

        chart = sheet1.charts.create('Open', sheet1[2:50, 7:18],
        sheet1[0:740, 0:6], row_header=TRUE, col_header=TRUE)
        diagram = chart.change_type(pyoo.LineDiagram)
        diagram.y_axis.title = "USD"
        diagram.y_axis.logarithmic = True

        chart = sheet2.charts.create('High', sheet2[2:50, 7:18], sheet2[0:740, 0:6],
        row_header=TRUE, col_header=TRUE)
        diagram = chart.change_type(pyoo.LineDiagram)
        diagram.y_axis.title = "USD"
        diagram.y_axis.logarithmic = True

        chart = sheet3.charts.create('Low', sheet3[2:50, 7:18],
```

```
sheet3[0:740, 0:6], row_header=TRUE, col_header=TRUE)
diagram = chart.change_type(pyoo.LineDiagram)
diagram.y_axis.title = "USD"
diagram.y_axis.logarithmic = True

chart = sheet4.charts.create('Close', sheet4[2:50, 7:18],
sheet4[0:740, 0:6], row_header=TRUE, col_header=TRUE)
diagram = chart.change_type(pyoo.LineDiagram)
diagram.y_axis.title = "USD"
diagram.y_axis.logarithmic = True

chart = sheet5.charts.create('Volume',
sheet5[2:28, 7:18], sheet5[0:740, 0:6],
row_header=TRUE, col_header=TRUE)
diagram = chart.change_type(pyoo.LineDiagram)
diagram.y_axis.title = "USD"
diagram.y_axis.logarithmic = True

chart = sheet6.charts.create('Market_Cap',
sheet6[2:28, 7:18], sheet6[0:740, 0:6],
row_header=TRUE, col_header=TRUE)
diagram = chart.change_type(pyoo.LineDiagram)
diagram.y_axis.title = "USD"
diagram.y_axis.logarithmic = True

reportDir = os.path.dirname(os.path.abspath('reports'))
                + "/reports/"
doc.save(reportDir + 'grafovi.ods')
except:
    tkinter.messagebox.showinfo('Dokument_ne_postoji',
    'Potrebno_je_prvo_generirati_prikaz_kategorija!')
```

Četvrta metoda analiza(db, god, cat, coi) na temelju primljenih argumenata specificira upit nad kojom kriptovalutom će se napraviti, za koju godinu i koju kategoriju te na temelju dobivenog Calc dokumenta radi graf iz kojeg opet možemo radit neku analizu kretanja vrijednosti kriptovalute ovisno o odabranim parametrima.

```
def analiza(self, db, god, cat, coi):

    if coi == 'Bitcoin':
        cursor = db.bitcoin.find({'Date': {'$regex': god}},
        {'Date' : 1, cat: 1})

    elif coi == 'Ethereum':
        cursor = db.ethereum.find({'Date': {'$regex': god}},
        {'Date' : 1, cat: 1})
```

```
elif coi == 'Litecoin':
    cursor = db.litecoin.find({'Date': {'$regex': god}},
                              {'Date': 1, cat: 1})

elif coi == 'Monero':
    cursor = db.monero.find({'Date': {'$regex': god}},
                             {'Date': 1, cat: 1})

elif coi == 'Ripple':
    cursor = db.ripple.find({'Date': {'$regex': god}},
                             {'Date': 1, cat: 1})

wb = xlwt.Workbook()

sheet = wb.add_sheet(coi)

sheet.write(0, 0, 'Datum')
sheet.write(0, 1, cat)

i = 1
for row in cursor:
    sheet.write(i, 0, str(row['Date']))
    if (cat == 'Volume' or cat == 'Market_Cap'):
        sheet.write(i, 1, int(str(row[cat]).replace(',', '')))
    else:
        sheet.write(i, 1, float(row[cat]))
    i = i + 1

reportDir = os.path.dirname(os.path.abspath('reports'))
            + "/reports/"
wb.save(reportDir + "analiza.ods")

subprocess.Popen(['soffice --accept="socket,host=localhost,
#####port=2002;urp;" --norestore --nologo --nodefault --# --headless'],
                 shell=True)

time.sleep(2)
desktop = pyoo.Desktop('localhost', 2002)
reportKat = os.path.dirname(os.path.abspath('reports'))
            + "/reports/analiza.ods"
doc = desktop.open_spreadsheet(reportKat)

sheet1 = doc.sheets[0]
```

```
chart = sheet1.charts.create(cat, sheet1[2:20, 4:20],
sheet1[0:cursor.count()+1, 0:2], row_header=TRUE,
col_header=TRUE)
diagram = chart.change_type(pyoo.LineDiagram)
diagram.y_axis.title = "USD"
diagram.y_axis.logarithmic = True

reportDir = os.path.dirname(os.path.abspath('reports'))
            + "/reports/"
doc.save(reportDir + 'analiza.ods')
```

Za kraj imamo linije koda koje instanciraju objekat klase Tk() koji nam služi za definiranje prozora i njegovih objekata, te pozivamo sami konstruktor klase kako bi se pokrenuo program.

```
root = Tk()
root.title("TBP_Projekt")
mc = MiningCoins(root)
root.mainloop()
```


Datum	Open	High	Low	Close	Volume	Market Cap
Aug 14, 2017	4066.1	4325.13	3989.16	4325.13	2,463,090,000	67,112,300,000
Aug 15, 2017	4326.99	4455.97	3906.18	4181.93	3,258,050,000	71,425,500,000
Aug 12, 2017	3650.63	3949.92	3613.7	3884.71	2,219,590,000	60,242,100,000
Aug 13, 2017	3880.04	4208.39	3857.8	4073.26	3,159,090,000	64,034,100,000
Aug 11, 2017	3373.82	3679.72	3372.12	3650.62	2,021,190,000	55,668,000,000
Aug 09, 2017	3420.4	3422.76	3247.67	3342.47	1,468,960,000	56,424,900,000
Aug 08, 2017	3370.22	3484.85	3345.83	3419.94	1,752,760,000	55,590,300,000
Aug 07, 2017	3212.78	3397.68	3180.89	3378.94	1,482,280,000	52,987,300,000
Aug 10, 2017	3341.84	3453.45	3319.47	3381.28	1,515,110,000	55,134,700,000
Aug 06, 2017	3257.61	3293.29	3155.6	3213.94	1,105,030,000	53,720,900,000
Aug 05, 2017	2897.63	3290.01	2874.83	3252.91	1,945,700,000	47,778,200,000
Aug 04, 2017	2806.93	2899.33	2743.72	2895.89	1,002,120,000	46,276,200,000
Aug 03, 2017	2709.56	2813.31	2685.14	2804.73	804,797,000	44,666,400,000
Aug 02, 2017	2727.13	2762.53	2668.59	2710.67	1,094,950,000	44,950,800,000
Aug 01, 2017	2871.3	2921.35	2685.61	2718.26	1,324,670,000	47,321,800,000
Jul 31, 2017	2763.24	2889.62	2720.61	2875.34	860,575,000	45,535,800,000
Jul 30, 2017	2724.39	2758.53	2644.85	2757.18	705,943,000	44,890,700,000
Jul 29, 2017	2807.02	2808.76	2692.8	2726.45	803,746,000	46,246,700,000
Jul 28, 2017	2679.73	2897.45	2679.73	2809.01	1,380,100,000	44,144,400,000
Jul 27, 2017	2538.71	2693.32	2529.34	2671.78	789,104,000	41,816,500,000
Jul 26, 2017	2577.77	2610.76	2450.8	2529.45	937,404,000	42,455,000,000
Jul 25, 2017	2757.5	2768.08	2480.96	2576.48	1,460,090,000	45,410,100,000
Jul 24, 2017	2732.7	2777.26	2699.19	2754.86	866,474,000	44,995,600,000
Jul 23, 2017	2808.1	2832.18	2653.94	2730.4	1,072,840,000	46,231,100,000
Jul 22, 2017	2668.63	2862.42	2657.71	2810.12	1,177,130,000	43,929,600,000
Jul 21, 2017	2838.41	2838.41	2621.85	2667.76	1,489,450,000	46,719,000,000
Jul 20, 2017	2269.89	2900.7	2269.89	2817.6	2,249,260,000	37,356,800,000
Jul 18, 2017	2233.52	2387.61	2164.77	2318.88	1,512,450,000	36,749,400,000
Jul 19, 2017	2323.08	2397.17	2260.23	2273.43	1,245,100,000	38,227,800,000
Jul 17, 2017	1932.62	2230.49	1932.62	2228.41	1,201,760,000	31,795,000,000
Jul 15, 2017	2230.12	2231.14	1990.41	1998.86	993,608,000	36,681,300,000
Jul 16, 2017	1991.98	2058.77	1843.03	1929.82	1,182,870,000	32,767,600,000
Jul 14, 2017	2360.59	2363.25	2183.22	2233.34	882,503,000	38,823,100,000
Jul 13, 2017	2402.7	2425.22	2340.83	2357.9	835,770,000	39,511,000,000
Jul 12, 2017	2332.77	2423.71	2275.14	2398.84	1,117,410,000	38,355,900,000
Jul 10, 2017	2525.25	2537.16	2321.13	2372.56	1,111,200,000	41,509,000,000
Jul 09, 2017	2572.61	2635.49	2517.59	2518.44	527,856,000	42,283,200,000
Jul 08, 2017	2520.27	2571.34	2492.31	2571.34	733,330,000	41,417,700,000
Jul 07, 2017	2608.59	2916.14	2498.87	2518.66	917,412,000	42,864,200,000
Jul 11, 2017	2385.89	2413.47	2296.81	2337.79	1,329,760,000	39,224,200,000
Jul 06, 2017	2600.1	2616.72	2501.60	2600.56	761,057,000	42,951,400,000

▶ ▶ +
Bitcoin
Etherium
Litecoin
Monero
Ripple


Slika 7.3: Prkaz svih kriptovaluta i vrijednosti

Datum	Bitcoin	Ethereum	Litecoin	Monero	Ripple			
Aug 14, 2017	4066.1	299.95	45.83	49.97	0.168376			
Aug 15, 2017	4326.99	298.03	46.57	47.69	0.16979			
Aug 12, 2017	3650.63	310.37	45.81	49.38	0.173545			
Aug 13, 2017	3880.04	308.71	47.05	50.85	0.179221			
Aug 11, 2017	3373.82	294.5	46.4	49.31	0.180175			
Aug 09, 2017	3420.4	296.96	48.59	50.94	0.192527			
Aug 08, 2017	3370.22	297.63	45.9	51.94	0.183168			
Aug 07, 2017	3212.78	269.1	45.17	50.4	0.179602			
Aug 10, 2017	3341.84	261.24	46.84	47.67	0.185398			
Aug 06, 2017	3257.61	256.42	48.05	48.57	0.179716			
Aug 05, 2017	2897.63	222.85	42.89	45.18	0.173865			
Aug 04, 2017	2806.93	225.31	42.19	43.36	0.173218			
Aug 03, 2017	2709.56	220.18	43.07	43.8	0.177531			
Aug 02, 2017	2727.13	227.01	43.02	44.08	0.168024			
Aug 01, 2017	2871.3	204.69	40.34	39.88	0.16505			
Jul 31, 2017	2763.24	197.41	41.18	39.67	0.169494			
Jul 30, 2017	2724.39	206.74	40.56	43.95	0.165218			
Jul 29, 2017	2807.02	193.34	42.22	43.69	0.174555			
Jul 28, 2017	2679.73	204.32	42.35	45.29	0.173211			
Jul 27, 2017	2538.71	204.86	42.29	45.92	0.177582			
Jul 26, 2017	2577.77	207.09	44.48	40.73	0.19228			
Jul 25, 2017	2757.5	224.37	44.16	45.55	0.194979			
Jul 24, 2017	2732.7	229.12	46.63	44.64	0.17521			
Jul 23, 2017	2808.1	217.86	45.77	40.25	0.193568			
Jul 22, 2017	2668.63	226.06	45.07	40.55	0.182168			
Jul 21, 2017	2838.41	205.42	40.96	34.89	0.18943			
Jul 20, 2017	2269.89	234.94	44.35	36.47	0.170017			
Jul 18, 2017	2233.52	195.03	42.62	34.89	0.188498			
Jul 19, 2017	2323.08	159.99	43.49	29.47	0.179668			
Jul 17, 2017	1932.62	169.57	41.19	31.97	0.150146			
Jul 15, 2017	2230.12	199.71	38.92	35.57	0.16948			
Jul 16, 2017	1991.98	209.53	42.81	38.08	0.190976			
Jul 14, 2017	2360.59	231.81	48.72	40.43	0.200819			
Jul 13, 2017	2402.7	197.15	45.26	36.89	0.205873			
Jul 12, 2017	2332.77	211.53	46.27	40.25	0.184198			
Jul 10, 2017	2525.25	243.01	49.91	44.91	0.196415			
Jul 09, 2017	2572.61	251.82	52.36	46.69	0.234067			
Jul 08, 2017	2520.27	245.89	46.64	44.17	0.236884			
Jul 07, 2017	2608.59	270.35	51.1	50.11	0.239741			
Jul 11, 2017	2385.89	268.86	53.2	45.96	0.254858			
Jul 06, 2017	2608.1	226.28	46.26	42.66	0.256274			
...								
► ◀ +	Open	High	Low	Close	Volume	Market Cap		

Slika 7.4: Kategorizacija



Slika 7.5: Grafovi po kategorijama



Slika 7.6: Prikaz grafa za korisničke određene parametre

## Poglavlje 8

# Zaključak

U ovom projektu vidjeli smo što je to pojam big data, kako je on povezan sa polustrukturiranim podacima, kakvu oni strukturu imaju i zašto su korisni. Isto tako smo se upoznali sa NoSQL-om te uvidjeli razlike sa klasičnim SQL-om odnosno relacijskim modelom. Vidjeli smo i što je to MongoDB, čemu služi, kako se koristi. Kroz rad je bilo prikazano kako instalirati MongoDB na Ubuntu 16.04 kako se koristi, kako smo kreirali bazu i dodali skupove podataka, na koji način se python može povezati na MongoDB bazu te kako smo pomoću pythona te podatke prikazali na sučelje LibreOffice Calca. S pythonom se to dalo lijepo odraditi ali nedostaje još malo nekih dodatnih mogućnosti sa bibliotekama te je teško pronaći dobre primjere i dokumentaciju za korištenje biblioteka koje mogu raditi sa LibreOffice Calcom. Međutim, na kraju se može uvidjeti da su se uspješno napravili određeni grafovi iz kojih se može izvući neka analiza podataka iz baze, te bi se lako aplikacija mogla nadograditi da ima još neke dodatne grafove za recimo još nižu razinu po mjesecu ili da se uzmu samo određene kriptovalute za određene parametre.



# Bibliografija

2016. *MongoDB Docs*.

2016. *Semi-structured data*.

2017. *Big Data*.

2017. *NoSQL*.

Machin, J., 2017. *xlwt 1.3.0*.

Pojman, M., 2017. *pyoo 1.2*.